پرنیا عظیمی
403100224

گزارش فاز ۱: شناخت داده، پاکسازی و سؤال آماری

موضوع: رابطهٔ شدت بیماری (CDR Sum of Boxes) با ضخامت قشر مغز در دادهٔ NACC (UDS + MRI)

---

۱. خلاصهٔ کار

در این فاز دو فایل را بررسی کردم: فایل بالینی (UDS) و فایل MRI. بعد از بررسی ساختار، پاکسازی و اتصال آن‌ها، گم‌شدگی داده را سنجیدم و متغیرها را توصیف کردم. در آخر از میان شش سؤال پیشنهادی، یک سؤال را انتخاب کردم.

- نمونهٔ نهایی: **۱۲۳۷ نفر** با هر دو فایل
- سؤال انتخاب‌شده: آیا نمرهٔ بالاتر CDRSUM با نازک‌تر بودن قشر انتورینال همراه است؟
- در این فاز فقط توصیف کرده‌ام و **ادعای آماری یا علّی** نکرده‌ام.

---

۲. منبع داده و نحوه جمع‌آوری

داده‌ها از NACC (مرکز هماهنگی ملی آلزایمر در آمریکا) هستند. این مرکز اطلاعات مراکز تحقیقاتی آلزایمر (ADRC) را که با پروتکل یکسان (UDS) افراد را ارزیابی می‌کنند جمع می‌کند. هر فرد معمولاً حدود سالی یک بار ویزیت می‌شود.

- **فایل UDS:** سن، جنس، تحصیل، تشخیص، نمرهٔ CDR، آزمون‌های شناختی، افسردگی، توانایی در کارهای روزمره (IADL) و سابقهٔ پزشکی.
- **فایل MRI:** ضخامت قشر مغز (_AVGTH، به میلی‌متر) و حجم ماده خاکستری (_GVOL) در ۳۱ ناحیه، برای نیمکرهٔ چپ (_LH) و راست (_RH)، یعنی ۱۲۴ متغیر.

نوع مطالعه: مشاهده‌ای است. شرکت‌کنندگان داوطلب‌اند، نمونه‌گیری تصادفی نشده و مداخله‌ای هم نبوده. پس فقط **همراهی** بین متغیرها را می‌توان دید و نه علت و معلول.

ویژگی‌های نمونه:

- سن: میانه ۶۸ سال (۶۳ تا ۷۴)، از ۴۱ تا ۹۱ سال

•۵۹٫۸٪ زن

•تحصیل: میانه ۱۶ سال (۱۴ تا ۱۸)

•تشخیص: ۶۸٫۵٪ شناخت طبیعی، ۲۰٫۴٪ MCI، ۱۰٫۶٪ زوال عقل، ۰٫۶٪ (۷ نفر) مختل ولی نه MCI»

قابلیت تعمیم: شرکت‌کنندگان داوطلب‌اند، در مراکز تحقیقاتی ارزیابی شده‌اند، تحصیلاتشان بالاست و ترکیب تشخیص‌ها را مراکز تعیین کرده‌اند، نه جمعیت. فقط کسانی وارد شده‌اند که MRI هم دارند. بنابراین نتایج دربارهٔ **همین گروه** است و به کل جامعه یا سالمندان عادی قابل تعمیم نیست.

---

۳. واحد مشاهده و ساختار داده

هر ردیف = یک شرکت‌کننده (یک رکورد UDS وصل‌شده به یک رکورد MRI).

فایل MRI	فایل UDS	
۱۲۳۷	۱۲۳۷	تعداد ردیف
۱۲۳۷	۱۲۳۷	یکتا NACCID
۰	۰	تکراری NACCID
۱	۱	بیشینهٔ ردیف برای هر نفر

نتیجه: ساختار «یک ردیف برای هر نفر» (تک‌زمانی) است. هیچ نفری دو بار وارد تحلیل نمی‌شود، پس **استقلال مشاهدات** رعایت می‌شود.

ویزیت: در هیچ‌کدام از دو فایل ستونی برای شمارهٔ ویزیت یا تاریخ پیدا نشد. پس تعداد ویزیت‌های هر نفر را نمی‌توان توصیف کرد. این‌که رکورد هر نفر مربوط به کدام ویزیت است در آماده‌سازی قبلی تعیین شده و در داده ثبت نیست. این را به‌عنوان محدودیت می‌نویسم.

---

۴. اتصال دو فایل

.به هم وصل شدند (inner join) «و اتصال «یک به یک NACCID دو فایل با

تعداد	
۱۲۳۷	شرکت‌کنندگان UDS
۱۲۳۷	شرکت‌کنندگان MRI
۱۲۳۷	در هر دو فایل
۰ / ۰	فقط UDS / فقط MRI

تعداد

۱۲۳۷ نمونهٔ نهایی

در دو فایل مقایسه شد و یکسان بود. چون هر دو فایل از قبل روی همین (تشخیص) NACCUDSD ستون مشترک .افراد محدود شده بودند، خود اتصال نمی‌تواند انتخاب (سوگیری) ایجاد کند

---

۵. پاکسازی داده

۵.۱. مشکل فایل UDS

از قبل «پر شده» بود: جاهای خالی را با میانگین ۵ نفر مشابه پر کرده بودند. (udslong_imputed.csv) فایل خام :دو نشانه

- •مقدارهایی مثل ۲۴٫۶ برای MoCA (میانگین ۵ عدد صحیح مضرب ۰٫۲ می‌شود)
- این‌ها فقط وقتی پیش می‌آیند که کد خطا .DEP2YRS = ۱٫۸ یا MoCA = ۳۹٫۴ مقدارهای غیرممکن مثل .(مثل ۸۸ یا ۹) بین همسایه‌ها بوده باشد

مقدار پرشدهٔ صحیح (مثلاً ۲۵) از مقدار واقعی قابل تشخیص نیست. پس تعداد NaNهای من **کمینهٔ** گم‌شدگی واقعی است و نباید آن را مقدار دقیق گرفت.

۵.۲. قواعد UDS

مقداری که در دامنهٔ مجاز نبود یا برای نمره‌ای که باید صحیح باشد غیرصحیح بود، NaN شد:

متغیر	مقدار مجاز
IADL آیتم ۱۰	۰، ۱، ۲، ۳
DEP2YRS	۰ یا ۱
SEX	۱ یا ۲
NACCUDSD	۱ تا ۴
MEMORY	۰، ۰٫۵، ۱، ۲، ۳
CDRSUM	۰ تا ۱۸ با گام ۰٫۵
NACCAGE	۱۸ تا ۱۱۰
EDUC	عدد صحیح ۰ تا ۳۶
MOCATOTS	عدد صحیح ۰ تا ۳۰
NACCGDS	عدد صحیح ۰ تا ۱۵

نتایج مهم:

- MOCATOTS: ۲۵۳ (۲۰٫۵٪) مقدار NaN که به همین دلیل سؤال‌هایی که MoCA شد کنار گذاشته شدند.
- EDUC: ۲ مقدار NaN شد.
- SEX، NACCUDSD، MEMORY، CDRSUM و NACCAGE: در هیچ مقداری CDRSUM **صفر** مقدار تغییر کرد. خارج از گام‌های ۰٫۵ نبود که نشانهٔ خوبی است که دست‌کاری نشده، ولی اثبات نیست.
- NACCAGE: اسکریپت قبلی ۸۸ و ۹۹ را کد خطا حساب می‌کرد، اما این‌ها می‌توانند سن واقعی باشند. سن را با فایل خام مقایسه کردم و کاملاً یکسان بود.

۵.۳. پاکسازی MRI

قاعده‌ها فقط از خود دادهٔ MRI استفاده می‌کنند و از تشخیص یا نمرهٔ بالینی استفاده نمی‌کنند. دلیلش این است که اگر بر اساس تشخیص حذف می‌کردیم، خودمان الگو را می‌ساختیم.

قاعدهٔ ۱: علامت‌زدن مقدار مشکوک. مقدار مشکوک است اگر:

- غیرممکن باشد: ضخامت کمتر از ۱ یا بیشتر از ۴٫۵ میلی‌متر، یا حجم صفر یا منفی (این مرزها را خودم انتخاب کرده‌ام، نه استاندارد رسمی)
- یا خیلی دور از بقیه باشد: بیش از ۳ برابر IQR از چارک‌ها فاصله دارد. (IQR یعنی فاصلهٔ بین چارک اول و سوم، پهنای «نیمهٔ میانیِ» داده.)

قاعدهٔ ۲: اسکن خراب. هر کس ۱۳ مقدار مشکوک یا بیشتر داشت (حدود ۱۰٪ از ۱۲۴ متغیر)، کل MRIاش NaN شد، چون وقتی بازسازی تصویر خراب شود، همهٔ اندازه‌ها خراب است. نتیجه: **۱۲ نفر** و ۵۶۳ مقدار.

قاعدهٔ ۳: نگه‌داشتن مقدار پایین محتمل. برای بقیه، مقدار پایینِ مشکوک اگر غیرممکن نبود و حداقل ۵۰٪ میانهٔ آن متغیر بود، نگه داشته شد، چون ممکن است آتروفی واقعی باشد. نتیجه: ۷۴ مقدار نگه داشته شد و ۶۴ مقدار NaN شد.

جمع: ۵۶۳ + ۷۴ + ۶۴ = ۷۰۱ مقدار علامت خورد. ۱۲ نفر MRI قابل‌استفاده ندارند و ۴۳ نفر دست‌کم یک مقدار MRI گم‌شده دارند.

۵.۴. تحلیل حساسیت

چون آستانه‌ها را خودم انتخاب کرده‌ام، هفت حالت را امتحان کردم: مرز ۲× و ۴× ، حذف اسکن از ۸ یا ۲۰ مقدار مشکوک، نگه‌داشتن فقط ≤ ۷۰٪ میانه، و هرگز برنگرداندن.

نتیجه در همهٔ حالت‌ها

اسکن‌های حذف‌شده	بین ۷ و ۲۰ نفر

نتیجه در همهٔ حالت‌ها	
میانهٔ انتورینال، CDRSUM = ۰	۳٫۱۱ میلی‌متر
میانهٔ انتورینال، CDRSUM ≥ ۵	۲٫۶۹ میلی‌متر
همبستگی رتبه‌ای (ρ) انتورینال	−۰٫۳۰ تا −۰٫۳۱

نتیجه: پاسخ تقریباً به انتخاب آستانه‌ها وابسته نیست.

۵.۵. کنترل‌های منطقی

کنترل	تعداد
تکراری NACCID	۰
خارج از ۰ تا ۱۸ یا خارج از گام ۰٫۵ CDRSUM	۰
(غیرممکن) MEMORY کمتر از CDRSUM	۰
سن خارج از ۱۸ تا ۱۱۰	۰
زوال عقل با CDRSUM = ۰	۰
ضخامت انتورینال خارج از ۱ تا ۴٫۵	۰
شناخت طبیعی با CDRSUM ≥ ۳	نفر ۱
اختلاف انتورینال چپ و راست بیش از ۱ میلی‌متر	نفر ۱۴

مورد غیرممکنی نبود. آن ۱ نفر و ۱۴ نفر ممکن است واقعی باشند، پس حذف نشدند و فقط گزارش شدند.

۵.۶. متغیرهای ساخته‌شده

- **TH_ENTORHINAL، TH_PARAHIPPOCAMPAL، TH_MIDDLETEMPORAL:** میانگین ضخامت چپ و راست. **این‌ها در سؤال نهایی استفاده می‌شوند** NaN بود، کل NaN اگر یکی .می‌شود
- **CDR_nonmemory:** CDRSUM − MEMORY
- **دو نمرهٔ IADL و سه شاخص عدم‌تقارن:** فقط اکتشافی هستند و در سؤال نهایی نیستند.

---

۶. گم‌شدگی داده

متغیر	تعداد گم‌شده	درصد
NACCAGE، SEX، NACCUDSD، CDRSUM، MEMORY	۰	۰٫۰
EDUC	۲	۰٫۲
NACCGDS	۱۴	۱٫۱
DEP2YRS	۱۶	۱٫۳

متغیر	تعداد گم‌شده	درصد
IADL_prorated	۱۹	۱٫۵
MOCATOTS	۲۵۳	۲۰٫۵
ضخامت MRI (هر ناحیه)	۱۲ تا ۱۳	۱٫۰ تا ۱٫۱

چه کسانی گم‌شده‌اند؟

	MoCA (n = ۹۸۴) با	**MoCA (n = ۲۵۳) بدون**
درصد شناخت طبیعی	۶۴٫۶	۸۳٫۴
درصد MCI	۲۳٫۰	۱۰٫۳
درصد زوال عقل	۱۲٫۰	۵٫۱
سن (میانه)	۶۹	۶۶

MoCA و زوال عقل. پس تحلیلی که MCI برای ۲۴٫۹٪ افراد طبیعی گم شده، ولی فقط برای حدود ۱۰٪ از MoCA لازم دارد، سالم‌ها را کمتر نشان می‌دهد.

۱۲ نفر بدون MRI قابل‌استفاده، نیمی MCI دارند (در مقابل ۲۰٫۱٪ بقیه). ولی با ۱۲ نفر نمی‌شود گفت این تفاوت واقعی است.

کاملی نمونه برای هر سؤال:

سؤال	موارد کامل	درصد
Q1 (MoCA و ضخامت)	۹۷۵	۷۸٫۸
Q2 (CDRSUM و ضخامت)	**۱۲۲۲**	**۹۸٫۸**
Q3 (حافظه و ضخامت)	۱۲۲۲	۹۸٫۸
Q4 (IADL و حجم)	۱۱۹۸	۹۶٫۸
Q5 (عدم‌تقارن)	۹۷۵	۷۸٫۸
Q6 (افسردگی)	۱۱۹۳	۹۶٫۴

---

۷. طبقه‌بندی متغیرها

متغیر	نقش	نوع	خلاصهٔ مناسب
CDRSUM	توضیحی	عددی گسسته (۶۱٪ صفر)	میانه و درصد صفرها
ضخامت انتورینال	پاسخ	عددی پیوسته	میانگین و انحراف معیار
NACCAGE	کنترل	عددی	میانگین و انحراف معیار

متغیر	نقش	نوع	خلاصهٔ مناسب
EDUC	کنترل	عددی گسسته	IQR میانه و
SEX	کنترل	اسمی دوحالته	فراوانی و درصد
NACCUDSD	گروه‌بندی	اسمی	فراوانی و درصد
MEMORY	گروه‌بندی	ترتیبی	فراوانی
IADL آیتم‌های	ترتیبی	ترتیبی	فراوانی

به‌خاطر ۶۱٪ صفر برای میانگین مناسب نیست: میانگین ۰٫۸۲ و انحراف معیار ۱٫۷۲ است (انحراف معیار CDRSUM نمرهٔ هم چوله است (میانه ۰۲۵، میانگین ۰۲۴) و سقف نزدیک ۳۰ دارد MoCA .دو برابر میانگین) و دنباله تا ۱۵ می‌رود.

---

۸. توصیف متغیرها

دسته‌ای:

- MEMORY: ۶۵٫۳٪ نمرهٔ ۰، ۲۱٫۳٪ نمرهٔ ۰٫۵، ۱۲٫۰٪ نمرهٔ ۱ و فقط ۱۷ نفر (۱٫۴٪) نمرهٔ ۲ یا ۳. این دو سطح آخر برای گروه‌بندی ادغام شدند.
- IADL: ۷۹ آیتم‌های REMDATES (۲۰٫۹٪). تا ۹۳٪ افراد «نرمال» هستند. بیشترین مشکل را دارد.
- DEP2YRS: ۱۹٫۲٪ پاسخ «بله».

عددی:

- CDRSUM: ۱ و ۰ چارک‌ها ۰، میانه ۰، از ۰ تا ۱۵
- NACCAGE: ۸٫۰ انحراف معیار ۶۸٫۲، میانگین
- ضخامت انتورینال چپ و راست: میانگین ۲٫۹۸ و ۳٫۰۷ میلی‌متر
- ضخامت‌های MRI تقریباً متقارن‌اند، با دنبالهٔ کوتاه به سمت چپ (آتروفی)

نقاط غیرعادی (بیرون از ۱٫۵×IQR):

متغیر	پایین‌تر از مرز	بالاتر از مرز
CDRSUM	۰	۱۱۵
MOCATOTS	۴۸	۰
انتورینال	۱۵	۱
پاراهیپوکامپال	۵	۱
تمپورال میانی	۳۲	۵

این مرزها معنی ندارند، چون چارک اول و سوم ۰ و ۱ هستند و هر نمرهٔ بالای ۲٫۵ «غیرعادی» CDRSUM برای هم افراد MoCA و MRI شمرده می‌شود، در حالی که این افراد بیماران شدیدترند، نه خطا. مقدارهای پایین بیمارتر هستند و حذف نشدند.

---

۹. نمودارها

هفت نمودار ساختم:

1. **توزیع CDRSUM** (دو پنل: همه، و فقط مقدارهای بیشتر از صفر)
2. **CDRSUM** (پراکنش با میانه‌ها) **در برابر ضخامت انتورینال**
3. **ضخامت سه ناحیه در چهار گروه CDRSUM**
4. **ضخامت بر حسب نمرهٔ حافظه**
5. **سن در برابر ضخامت انتورینال، جدا برای زن و مرد**
6. **توزیع ضخامت انتورینال و MoCA**
7. **ضخامت بر حسب الگوی اختلال** (حافظه، غیرحافظه، هر دو)

در نمودارها محور و واحد و عنوان کامل است و نمودار سه‌بعدی یا گمراه‌کننده نیست.

---

۱۰. مقایسهٔ توصیفی اولیه (بدون استنباط)

میانهٔ ضخامت (میلی‌متر) بر حسب گروه CDRSUM:

گروه	تعداد	انتورینال	پاراهیپوکامپال	تمپورال میانی	سن (میانه)
۰	۷۵۷	۳٫۱۱	۲٫۶۲	۲٫۶۲	۶۷
۰٫۵ تا ۱٫۵	۲۹۱	۳٫۰۲	۲٫۵۴	۲٫۵۹	۷۱
۲ تا ۴٫۵	۱۴۱	۲٫۷۹	۲٫۴۷	۲٫۵۲	۷۱
۵ و بیشتر	۴۸	۲٫۶۹	۲٫۳۹	۲٫۴۰	۷۰٫۵

همبستگی رتبه‌ای (ρ): عددی بین ۱− و ۱+. منفی یعنی با بالا رفتن یکی، دیگری معمولاً پایین می‌آید.

ناحیه	با CDRSUM	با حافظه	با سن
انتورینال	−۰٫۳۱	−۰٫۳۲	−۰٫۲۸
پاراهیپوکامپال	−۰٫۲۵	−۰٫۲۴	−۰٫۲۰
تمپورال میانی	−۰٫۳۱	−۰٫۳۱	−۰٫۲۴

مشاهدات (فقط توصیفی):

- میانهٔ ضخامت در هر سه ناحیه پایین می‌آید. اما محدودهٔ چارکی گروه‌های کنار هم، CDRSUM با بالا رفتن زیاد هم‌پوشانی دارد: یک **روند** است، نه یک جدایی کامل.
- گروه‌های بیمارتر حدود ۴ سال مسن‌ترند و ضخامت با سن هم کم می‌شود. حتی در افراد با CDRSUM = ۰، رابطهٔ ضخامت و سن مشابه است (حدود ۰٫۲۸− برای انتورینال ρ). پس **سن باید در نظر گرفته شود**.
  - ضخامت بین زن و مرد تقریباً یکی است.
- CDRSUM و نمرهٔ حافظه تقریباً یک متغیرند (ρ = ۰٫۹۴).
  - ضخامت با شدت غیرحافظه‌ای (ρ ≈ ۰٫۲۸−) تقریباً به اندازهٔ شدت حافظه‌ای (ρ ≈ ۰٫۳۲−) همبسته است. در نمودار ۷: گروه «هر دو» نازک‌ترین قشر را دارد (انتورینال ۲٫۸۶) و «فقط حافظه» (۳٫۰۳) و «فقط غیرحافظه» (۳٫۱۴) به گروه «هیچ‌کدام» (۳٫۱۱) نزدیک‌اند. پس این داده شواهد توصیفی روشنی نمی‌دهد که اختلال حافظه **به‌طور اختصاصی** با نازک‌شدن قشر ارتباط داشته باشد.
  - گروه «نمرهٔ حافظه ≤ ۲» فقط ۱۷ نفر است (۸۸٫۲٪ زن)، پس با احتیاط تفسیر شود.

---

۱۱. انتخاب سؤال

از شش سؤال پیشنهادی، **Q2** انتخاب شد:

سؤال	وضعیت	دلیل
Q1، Q5	کنار گذاشته	در ۲۰٫۵٪ گم‌شده و گم‌شدگی‌اش وابسته به تشخیص است MoCA
Q3	Q2 ادغام در	(ρ = ۰٫۹۴) است CDRSUM نمرهٔ حافظه تقریباً همان
Q4	کنار گذاشته	شده‌اند و حجم مغز بدون حجم کل جمجمه قابل impute احتمالاً قبلاً IADL آیتم‌های تعدیل نیست
Q6	کنار گذاشته	نشانهٔ توصیفی ضعیف
Q2	**انتخاب شد**	تقریباً برای همه موجود است MRI کامل‌ترین داده (۹۸٫۸٪) و ضخامت

---

۱۲. سؤال نهایی

با نازک‌تر بودن قشر (CDR Sum of Boxes (CDRSUM آیا نمرهٔ بالاتر NACC، در میان ۱۲۳۷ شرکت‌کنندهٔ انتورینال (میانگین چپ و راست) همراه است، پس از در نظر گرفتن سن، جنس و سال‌های تحصیل؟

فایل	نوع	متغیر	بخش
UDS	عددی، با صفرهای زیاد	CDRSUM	نمرهٔ بالینی
MRI	عددی پیوسته	ضخامت انتورینال (میانگین چپ و راست)	اندازهٔ مغز
UDS	عددی، دسته‌ای، عددی	NACCAGE، SEX، EDUC	در نظر گرفته می‌شوند

پاراهیپوکامپال و تمپورال میانی فقط توصیفی بررسی می‌شوند. **نمونه:** ۱۲۲۲ نفر از ۱۲۳۷ نفر (۹۸٫۸٪) همهٔ مقدارهای لازم را دارند.

وصل می‌شوند NACCID با .MRI می‌آیند و ضخامت از UDS **چرا هر دو فایل لازم است:** نمرهٔ بالینی و کوواریت‌ها از .تا نمرهٔ هر فرد با مغز خودش مقایسه شود

چرا داده برای این سؤال مناسب است:

- داده تقریباً کامل است.
- شرکت‌کنندگان از سالم تا زوال عقل را می‌پوشانند، پس هر دو متغیر تغییر می‌کنند.
- جدول‌ها نشان می‌دهند میانهٔ ضخامت با بالا رفتن CDRSUM (۳٫۱۱ تا ۲٫۶۹ میلی‌متر) پایین می‌آید.
- ضخامت به اندازهٔ سر کمتر وابسته است. این مهم است چون حجم کل جمجمه را نداریم.

---

۱۳. محدودیت‌ها

1. **داده یک عکس لحظه‌ای است:** همراهی را می‌بینیم، نه علت و معلول را.
2. **نمونهٔ مراکز تحقیقاتی:** تصادفی نیست، تحصیلات بالاست و ترکیب تشخیص‌ها را مراکز تعیین کرده‌اند.
3. **CDRSUM** (≤ ۵: ۴۸ نفر) و بالاترین گروه کوچک است (۶۱٪) **عمدتاً صفر است**.
4. **سن با شدت در هم آمیخته است:** افراد بیمارتر مسن‌ترند و ضخامت با سن کم می‌شود.
5. **دادهٔ imputeشده:** مقدار واقعی گم‌شدگی نامعلوم است و کدگذاری IADL هنوز با کتابچهٔ NACC تأیید نشده است.
6. **آستانه‌های پاکسازی تصمیم‌های من هستند:** ۱۲ اسکن کامل کنار رفت و تحلیل حساسیت نشان داد نتیجه تقریباً ثابت است.
7. **ویزیت مشخص نیست:** نمی‌دانیم هر رکورد مربوط به کدام ویزیت است.
8. **دور باطل:** تشخیص بالینی بخشی از نمرات CDR را به کار می‌برد، پس تشخیص به‌عنوان متغیر کنترل استفاده نمی‌شود.

---

۱۴. خروجی‌های فاز ۱

وضعیت	خروجی
این گزارش	reports/phase1.pdf
کارت پروژه	PROJECT_CARD.md
پوشهٔ src/ و run_all.sh	کد قابل بازتولید
uds_final.csv، mri_final.csv، analysis_dataset.csv، mri_cleaning_log.csv	فایل‌های داده
